


基于COT的新快慢思考架构实验

当前意图架构的问题

本质上现在还是NLU的做法增强版，并不是真正充分应用大模型思考能力的架构。



1. 意图、拒识判断输入单一，仅有query

当前意图模型只能从query衡量后续链路如何分配，但query的信息太少，仅此单一维度分类，不能判断正确答案，即便是人类（无数在badcase面前纠结的客户、测试和产品）在判断很多badcase时，都只能具体问题具体分析，很难达成统一标准。

假设要把所有信号都给意图模型来识别，那SFT的成本会指数级复杂。

例如：

- 空调没开时，说“我好热”，应该控制空调降温，当如果空调已经开得最冷，说“我好热”，没有可控制的东西了，就应该对话回复“空调已经开最低了，耐心等等，马上就会最凉了”
- 在模型问想听什么歌，回“周杰伦”，应该放歌；单独空说“周杰伦”，应该拒识；闲聊聊到“周杰伦”，应该聊天；

2. 靠造数据学习，case是造不完的

参考一个人类的合理决策过程，除了要丰富的输入参考综合决策，还需遵循一套场景的经验流程，往往有处理原则、规程、场景、可行行动项、参考经验等等一系列信息来支持潜在逻辑。当前的意图模型架构，只能通过学数据例子。缺少内在的思考逻辑，会有无尽难解的bug。

造数据维护和优化成本极高，仍然是NLU的人肉解bug方法，难以满足不同车企不同的仲裁处理需求，并且数据标准非常难以定义。

例如：

- 需要定义模糊意图时反问不执行，就要定义什么是模糊的，我们只能提炼出一些原则，例如表达不完整，表达不够明确，但是细化标注case，是很难定义的，如“好热”，不算模糊意图，开空调能解决，不用反问；但好暗，算模糊，因为不知道是屏幕暗，还是车内暗，得问清楚。

通过上面case可以看到，通过数据标注，是没法把内在逻辑传递给模型的，造成只会依样画葫芦，新的场景就会出badcase。

其他参考：[📄【4月】主线意图优化需求整理](#) [📄【生态交付】【转主线】Badcase反馈问题表](#) [📄固安测试问题集](#)

3. 意图的处理的信息量太少，后面链路的压力太大

当前意图只对几个粗的domain进行分类，有些链路后续的执行是很简单的，比如查天气，但有些非常复杂，比如车控，就有上千个函数，效果远差于只有少量函数的情况。但参考人的思维链路，信息处理流程是平衡的，说到热，就开窗、空调、加热几个选项去考虑解决，不会想到车控，在车控1千个范围内思考。

因此，应该增强意图的决策能力，减轻后续链路的负担。

当前的模糊多函数、状态推理车控，亟待解决，如路特斯和赛力斯高优先级关注。

注：根据吉利的量产数据，约30%的车控指令为复杂、模糊表达指令，原来清晰的指令NLU无法承接，证明用户有模糊复杂的表达需求（明确清晰的指令对用户的学习成本和表达成本高）

理想架构


基于以上问题，当前急需参考行业流行的mcp agent的方式，通过思维链推理，

- 参考多维度感知的信息决策
- 基于人提炼经验和原则（车企各不相同）来决策
- 将执行结论前置，解决后续链路的负担

实现把将扁平的分类逻辑，通过COT升级成立体的思维链流程逻辑。

参考人类处理的逻辑，将思考架构分成三层

端云一体的AIOS能力边界



1. 感知层——根据需求，识别出所需要参考的知识、处理要求、场景状态信号、可执行功能
2. 思考层——根据设定的链路要求，已经输入层提供的信息，通过类COT输出执行链路。
3. 执行层——根据思考链路，综合执行子模型结果，并在异常时，回到思考层处理。

预期效果


1. 决策和执行结果更智能（感受到模型在理解整个环境和用户需求）。
2. 将处理逻辑开放出来，支持车企定制，支持RAG热插拔改造（减少人肉解case的成本）。
3. 和用户的交互体验上，能更清晰解释思考，长步骤任务也能让用户接受合理时延（提升处理可解释性）。
4. 性能不衰减（高频场景仍然速度保障，只在用户接受的复杂场景慢一点）
5. 通过思考的解释过程，将错误原因透明化（支持auto pe）。
6. 有最强的老师，能自动化挖掘badcase，形成数据闭环（支持后续强化学习）
7. 通过推理思考架构，实现复杂的个性化主动服务推荐。（真正理解用户需求习惯，而不是死板预设）

技术机会

1. 字节深度推理模型pro 1.5第一梯队水平。
2. 可以在推理过程中截取中间结果，往后向运行，节省性能。
3. 边想边搜的技术，实现了流式持续塞入参考信息，可以不打断生成。
<https://medium.com/@techsachin/research-llm-training-framework-to-reason-with-search-via-reinforcement-learning-bf65478c0fa3>
 - a. 可以解决当前RAG检索本身推理弱的问题，可以减少初始的塞入的信息，减少干扰，减少首token时间。
 - b. 不增加模型调用的延迟
4. seed向量检索升级。

基于以上新技术效果，能够做到快速的又聪明的推理思考能力

快慢思考设计预想



示例

query: 雨刮器怎么这么慢？

现状: 意图进入车书，进入车控分不清楚

理想输出示例:

结合上下文，该query是【人机对话】

参考【雨刮器=自动模式】状态，视觉图像【驾驶员在手动拨雨刮器，表情焦虑】
可以直接执行【雨刮器速度调节】 【车控操作】
无可参考【个性记忆】
因为用户表达了疑问，需要【询问引导】在控制后向用户询问是否满足诉求

query：终点附近有什么好玩的地方？

现状：无法利用状态和记忆

输出示例：

结合上下文，该query是【人机对话】

参考【导航目的地=人民广场】状态，视觉图像【副驾坐着儿童】

可以直接执行【POI推荐】 【导航操作】


可参考【个性记忆】 【曾去过儿童运动观】

查到相关【POI要求】 【减少推荐按摩洗浴类场所】

因为用户表达了疑问，需要【回复引导】提供推荐POI的理由

实验方案和计划

方案



A：推理重构拒识+意图

- 通过引入cot反思，把当前拒识和意图的定义标准，作为PE，实验cot推理的效果
- 意图拆解为：控制动作（把现在的意图和FC一级功能合并），询问，对话，拒识

- 通过cot的思考原因，反过来优化PE，验证最强推理模型可达到的效果上限，当前测试集的正确率
- 流式截取推理结论，验证性能的上限

B：意图中，增加FC执行动作的关键结论推理

- 在初始SP中，增加更粗粒度的FC功能项，例如空调、座椅，包含功能的详细可操作描述
- 当意图为控制动作时，输出结论描述，验证推理复杂意图，对各类query推理出执行结论的正确性
- 将结论灌入FC执行，并设计简化的FC模版，提升性能

C：输入状态参考信息

- 在PE中先仿真，动态插入参考信息，供模型参考推理
- 增加边想，边搜索状态参考实验

D：记忆提取和应用

- 边想边搜中，查看是否需要额外记忆补充
- 输出完执行结论后，判断是否要保存提取相关记忆

实验步骤

第一步：搭建初步框架

- 验证新cot，意图拒识、FC的推理效果。

→：判断是否人机对话（给一个人机对话标准参考）

→：判断是否需要参考某些知识或者车辆状态，若需，输出需要哪些状态（给一个状态参考表）（给一个是否要参考状态的标准）

→：判断是否要调用某些功能，来满足要求（可执行功能参考）（给一个执行功能的原则），若要执行，执行的结果项及调用要求描述。

→：最后话术要求，询问澄清，基于功能执行结果响应，纯聊天，信息回答

- 验证是否能有稳定格式，能保证在流式生成过程中，第一时间截取到中间结果，影响执行链路。
- 验证性能效果
- 验证边想边搜的能力，提供一个可搜索的状态清单，通过仿真数据，让模型参考搜索

第二步：尝试优化FC

- 基于思考给出的结果，输送到简化版FC，观察效果
- 重点分析对FC的帮助，看是否能优化复杂FC的推理，看到智能上限的效果
- 实验是否能达到性能的平衡

第三步：尝试优化拒识、意图和推理效果

- 重点分析对于拒识和意图的优化效果，主要看性能能否优化到替代当前方案
- 分析状态参考，能否优化到可应用

基于以上实验，判定：

- 该架构是否是下阶段可用的方案，判断标准：
 - 能解决当前意图和FC的难点问题
 - 有其他知识参考、状态参考潜力
 - 实现最终端到端性能达到同等水平
- 若不可用作线上运行，则作为badcase挖掘和慢思考主动服务方向优先应用

应用目标阶段

阶段一：FC优化（6月）

- 模糊+状态参考推理理解
- “朋友上车”记忆

阶段二：拒识、意图优化（6月之后）

- 快速推理，分辨人机交互
- 意图架构重构，通过推理来判定

阶段三：个性记忆、场景推荐优化（7月之后）

- 记忆用户个性偏好
- 更合理的场景推荐

